Estacionariedade

Daniel Freitas

Instituto J&F
Centro de Educação para os Negócios

Estacionariedade

Estacionariedade: definição

Denominamos uma série temporal **estacionária** quando as suas propriedades estatísticas não mudam ao longo do tempo.

É importante descobrir se uma série é estacionária ou não pois muitos modelos preditivos partem desse principio.

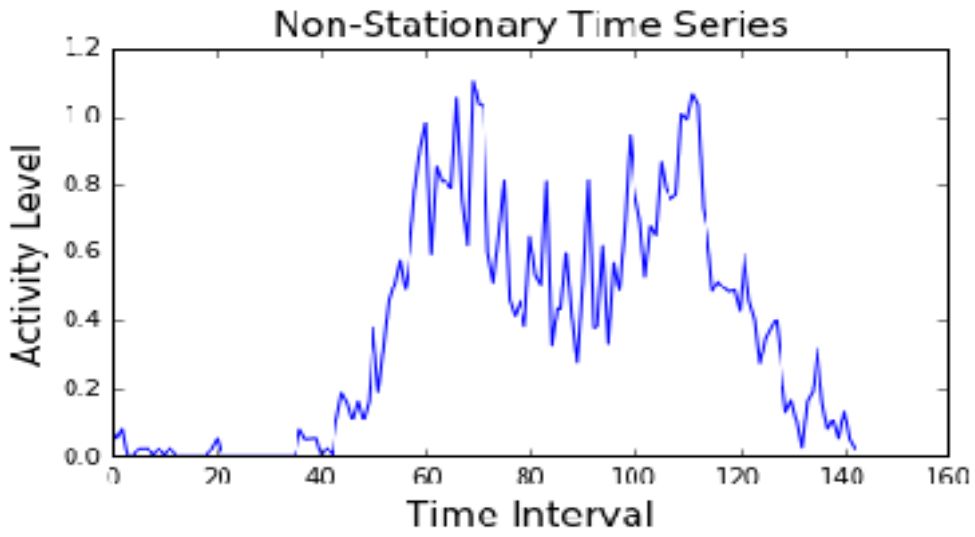

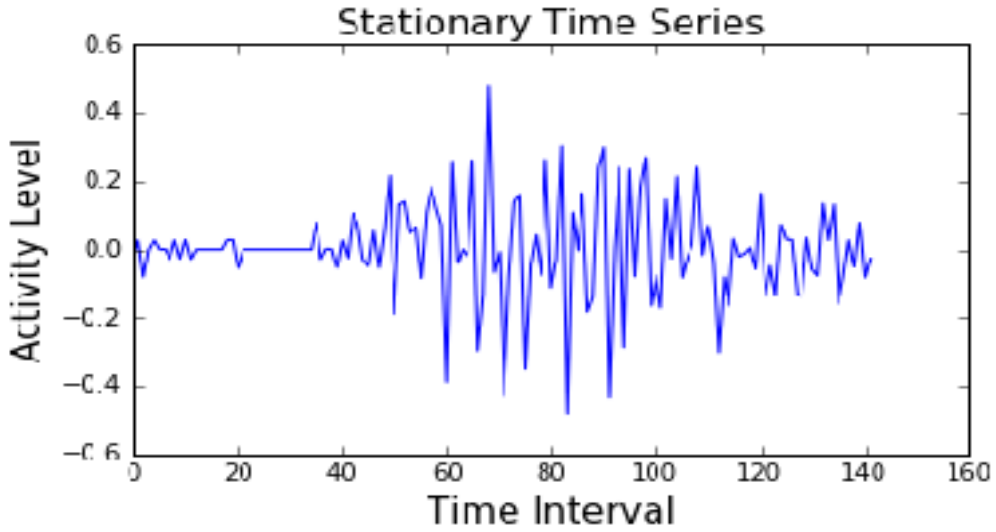

Estacionariedade: tipos

Estrita ou Forte: a distribuição de qualquer subconjunto não muda ao longo do tempo. Difícil de verificar na prática. **Ex: Bernoulli para o lançamento de uma moeda**

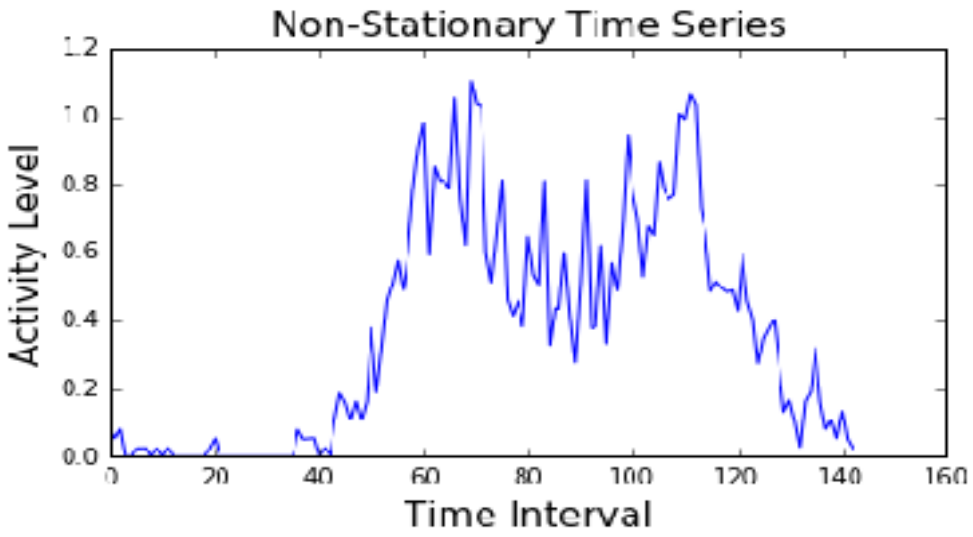

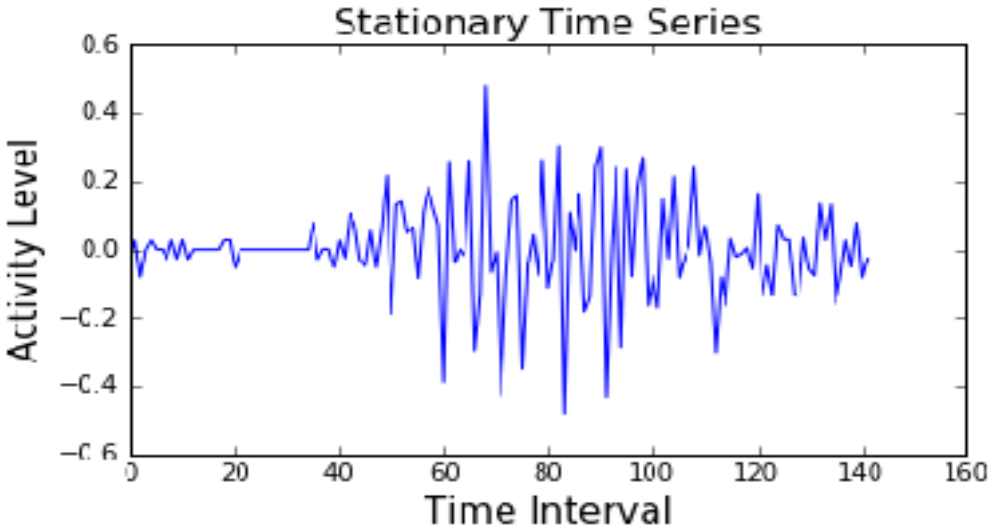

Estacionariedade: tipos

Fraca: uma série (y_t) é fracamente estacionária se satisfaz 3 condições abaixo:

- Média constante no tempo

$$E[y_t] = \mu, \quad \forall t$$

- Variância constante no tempo

$$Var(y_t) = \sigma^2, \quad \forall t$$

- Autocovariância depende do lag e não do tempo, ou seja, a relação entre os pontos se mantem

$$Cov(y_t, y_{t+k}) = \gamma_k, \quad \text{depende só de } k, \text{ não de } t$$

Essa estacionariedade é suficiente para a maioria dos modelos que virão

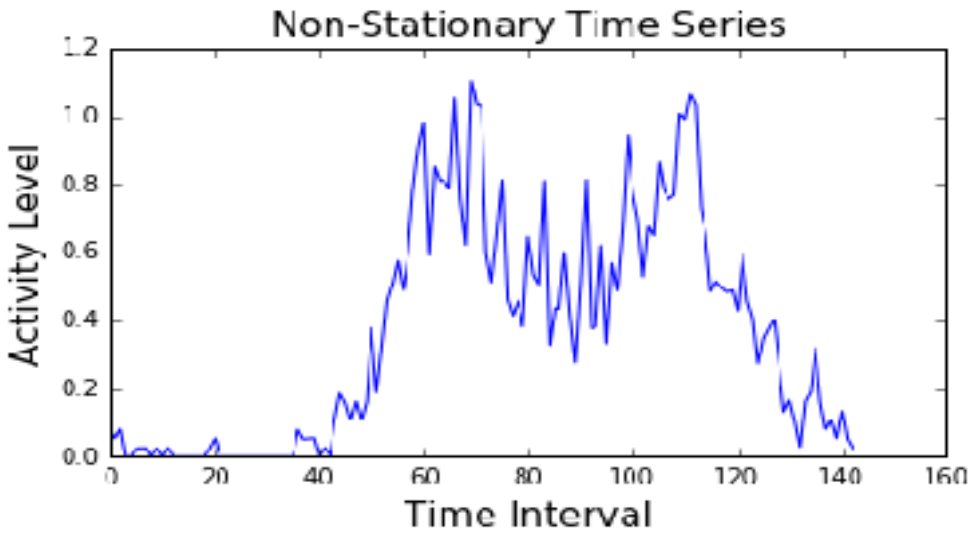

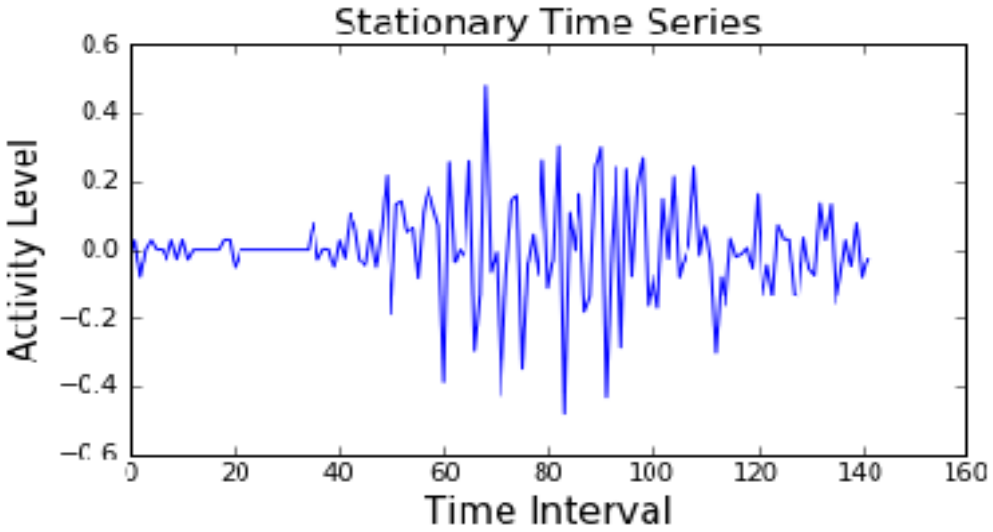

Covariância

Covariância:

Covariância é uma medida que indica o **grau em que duas variáveis aleatórias (X e Y) variam juntas**. É definida como:

$$Cov(X,Y) = \frac{\sum(X_i - \bar{X})(Y_i - \bar{Y})}{n}$$

Ano	PIB (trilhões)	Desemprego (%)
2019	21,5	3,5
2020	20,9	8,1
2021	22	5,9
2022	23,5	4,2
2023	24	3,8

Quando positiva (+) indica que as variáveis tendem a se mover na mesma direção

Quando negativa (-) indica que as variáveis tendem a se mover na direção oposta

Covariância: exemplos

Exemplo 1

Horas_Estudo	Nota
1	2
2	3
3	5
4	4
5	6
6	7
7	9
8	10

Exemplo 2

Videogame	Horas_Estudo
10	3
12	6
8	4
14	5
17	0

Autocovariância

Autocovariância

Calculamos a média da série e a utilizamos em uma defasagem k, esse valor tende a se manter constante:

covariância

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu_X)(Y_i - \mu_Y)$$

autocovariância

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

Lembrando que a covariância tenta responder a pergunta: “Quando uma variável aumenta, a outra tende a aumentar, diminuir ou não mudar?”

Autocovariância

Calculamos a média da série e a utilizamos em uma defasagem k, esse valor tende a se manter constante:

covariância

$$\mathrm{Cov}(X,Y) = \frac{1}{n}\sum_{i=1}^{n}(X_i - \mu_X)(Y_i - \mu_Y)$$

autocovariância

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

A autocovariância tenta responder à pergunta: “Quando um valor da série aumenta, os valores anteriores (ou futuros) da mesma série tendem a aumentar, diminuir ou não mudar?”

Autocovariância: exemplo

Considere a série abaixo, vamos calcular para o lag **k = 1**:

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

Autocovariância: exemplo

Considere a série abaixo, vamos calcular para o lag **k = 1**:

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

	serie	serie k =1
não uso	5	-
	7	5
	6	7
	8	6
	7	8
	9	7

média	7

y_t - media	y_t+k - media	Produto
0	-2	0
-1	0	0
1	-1	-1
0	1	0
2	0	0

soma	-1
autocov	-0,16667

Autocovariância: exemplo

Faça agora para o lag k =2

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

Autocovariância: exemplo

Faça agora para o lag k =2

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

	serie	serie k =2
não uso	5	-
	7	-
	6	5
	8	7
	7	6
	9	8

média	7

y_t - media	y_t+k - media	Produto
-1	-2	2
1	0	0
0	-1	0
2	1	2

soma	4
autocov	0,666667

Autocovariância: exemplo

Faça agora para o lag k =0, a chamada variância:

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

Autocovariância: exemplo

Faça agora para o lag k =0, a chamada variância:

Y = [5, 7, 6, 8, 7, 9]

$$\gamma(k) = \frac{1}{n}\sum_{t=1}^{n-k}(Y_t - \bar{Y})(Y_{t+k} - \bar{Y})$$

serie	serie k =0
5	5
7	7
6	6
8	8
7	7
9	9

y_t - media	y_t+k - media	Produto
-2	-2	4
0	0	0
-1	-1	1
1	1	1
0	0	0
2	2	4

média	7

soma	10
autocov	1,666667

Autocorrelação

Autocorrelação:

Autocorrelação é como perguntarmos: **‘O quanto o presente se parece com o passado, em média?’** E ao padronizarmos pela variância, conseguimos enxergar isso de forma clara e comparável, mesmo entre séries muito diferentes.

$$\rho(k) = \frac{\mathrm{Cov}(Y_t,\ Y_{t+k})}{\mathrm{Var}(Y_t)} = \frac{\gamma(k)}{\gamma(0)}$$

Autocorrelação:

Autocorrelação é como perguntarmos: **‘O quanto o presente se parece com o passado, em média?’** E ao padronizarmos pela variância, conseguimos enxergar isso de forma clara e comparável, mesmo entre séries muito diferentes.

$$\rho(k) = \frac{\mathrm{Cov}(Y_t,\ Y_{t+k})}{\mathrm{Var}(Y_t)} = \frac{\gamma(k)}{\gamma(0)}$$

autocorrelação para os casos anteriores

$$\rho(0) = 1$$

$$\rho(1) = -0{,}10$$

$$\rho(2) = 0{,}4$$

Python na prática

Base:

Considere a base ‘est_nao_est.xlsx’, faça a leitura da base e plotagem da série:

```
# plot das series
df.plot(subplots=True, figsize=(10, 6), title=["Série Estacionária",
                                               "Série Não Estacionária"])
plt.tight_layout()
plt.show()
```

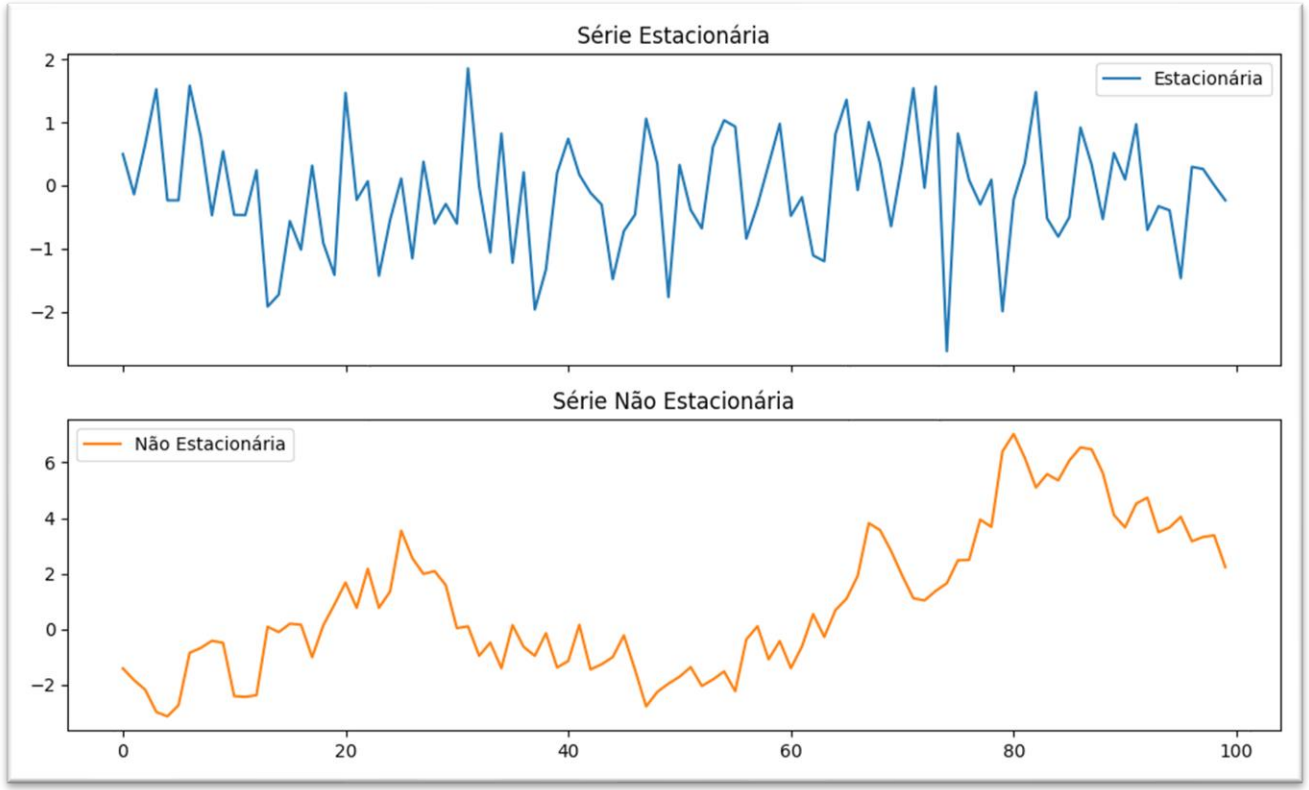

Funções:

Implemente as funções de autocovariancia e autocorrelação:

Funções:

Implemente as funções de autocovariancia e autocorrelação:

```python
# funcao calcular a autocovariância ( populacional)
def autocovariance(series, lag):
    n = len(series)
    mean = np.mean(series)
    return np.sum((series[lag:] - mean) * (series[:n - lag] - mean)) / n

# funcao para calcular a autocorrelação
def autocorrelation(series, lag):
    return autocovariance(series, lag) / autocovariance(series, 0)
```

Cálculo:

Utilize as funções para calcular autocorrelação e autocovariância para as séries considerando ¼ de lags, ou seja, para 0 a 25 lags da serie. Armazene em arrays:

Cálculo:

Utilize as funções para calcular autocorrelação e autocovariância para as séries considerando ¼ de lags, ou seja, para 0 a 25 lags da serie. Armazene em arrays:

```
# calculo autocovariância e autocorrelação para varios lags
# lags observados pode ser 1/4 da serie
max_lag = 25
lags = range(0, max_lag + 1)
auto_cov_est = [autocovariance(serie_estacionaria, lag) for lag in lags]
auto_cov_nao = [autocovariance(serie_nao_estacionaria, lag) for lag in lags]
auto_corr_est = [autocorrelation(serie_estacionaria, lag) for lag in lags]
auto_corr_nao = [autocorrelation(serie_nao_estacionaria, lag) for lag in lags]
```

Plot: autocovariâncias

Realize a plotagem das autocovariâncias das duas series:

Plot: autocovariâncias

Realize a plotagem das autocovariâncias das duas series:

```python
# plot das autocovariâncias
plt.figure(figsize=(10, 4))
plt.plot(lags, auto_cov_est, marker='o', label='Estacionária')
plt.plot(lags, auto_cov_nao, marker='o', label='Não Estacionária')
plt.title('Autocovariância por Lag')
plt.xlabel('Lag')
plt.ylabel('Autocovariância')
plt.legend()
plt.grid(True)
plt.show()
```

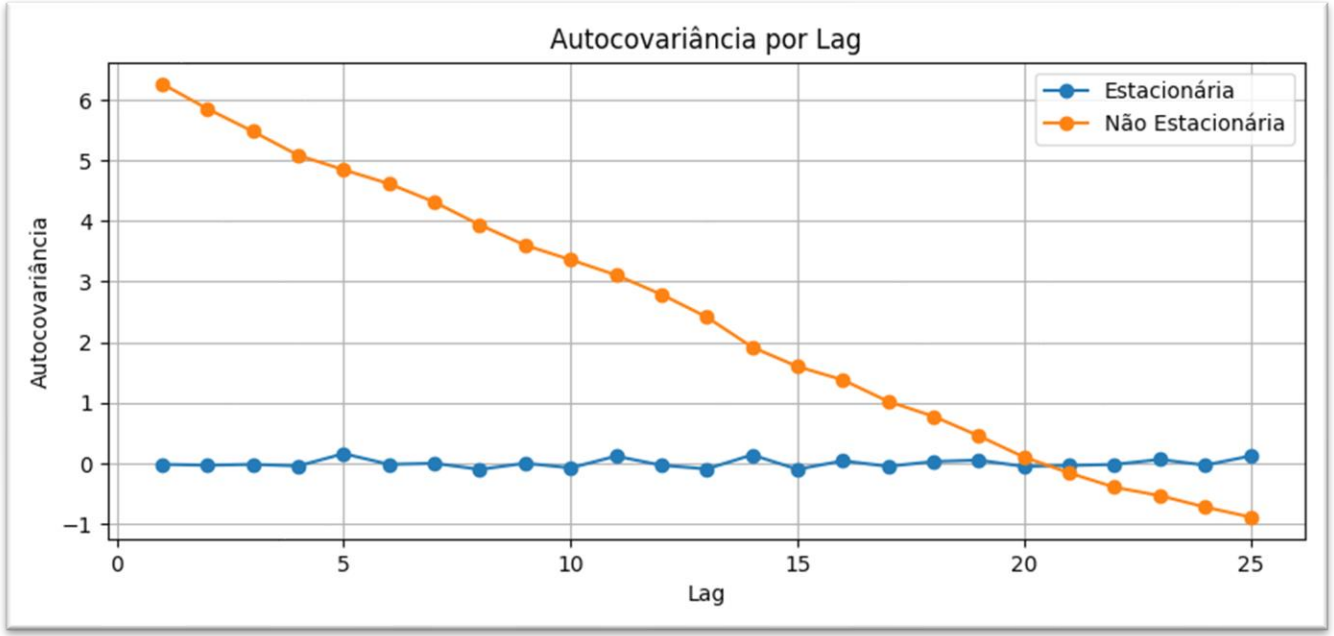

Plot: autocovariâncias

Realize a plotagem das autocorrelações das duas series:

Plot: autocovariâncias

Realize a plotagem das autocorrelações das duas series:

```
# plot das autocorrelações
plt.figure(figsize=(10, 4))
plt.plot(lags, auto_corr_est, marker='o', label='Estacionária')
plt.plot(lags, auto_corr_nao, marker='o', label='Não Estacionária')
plt.title('Autocorrelação (manual) por Lag')
plt.xlabel('Lag')
plt.ylabel('Autocorrelação')
plt.legend()
plt.grid(True)
plt.show()
```

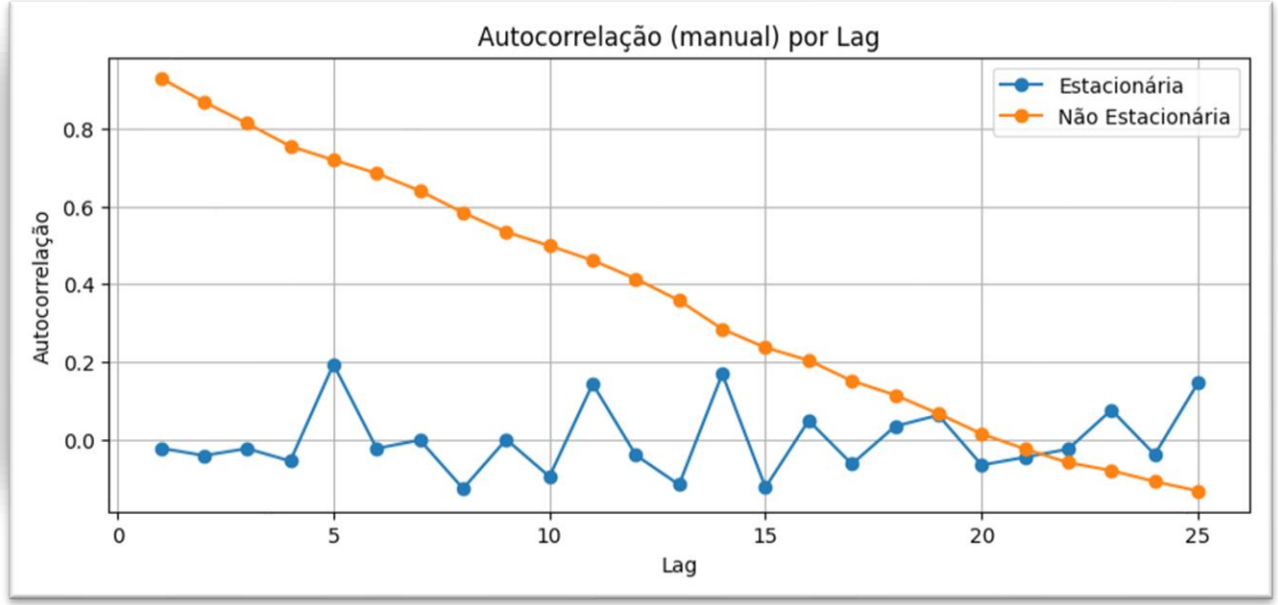

Plot: com biblioteca – mais simples

Um jeito muito mais simples de plotar esses gráficos é utilizar a função **plot_acf**:

```
from statsmodels.graphics.tsaplots import plot_acf
```

```
# plot das autocorrelações com statsmodels (ACF)
plt.figure(figsize=(10, 4))
plot_acf(serie_estacionaria, lags=max_lag, title='ACF - Série Estacionária')
plt.show()

plt.figure(figsize=(10, 4))
plot_acf(serie_nao_estacionaria, lags=max_lag, title='ACF - Série Não Estacionária')
plt.show()
```

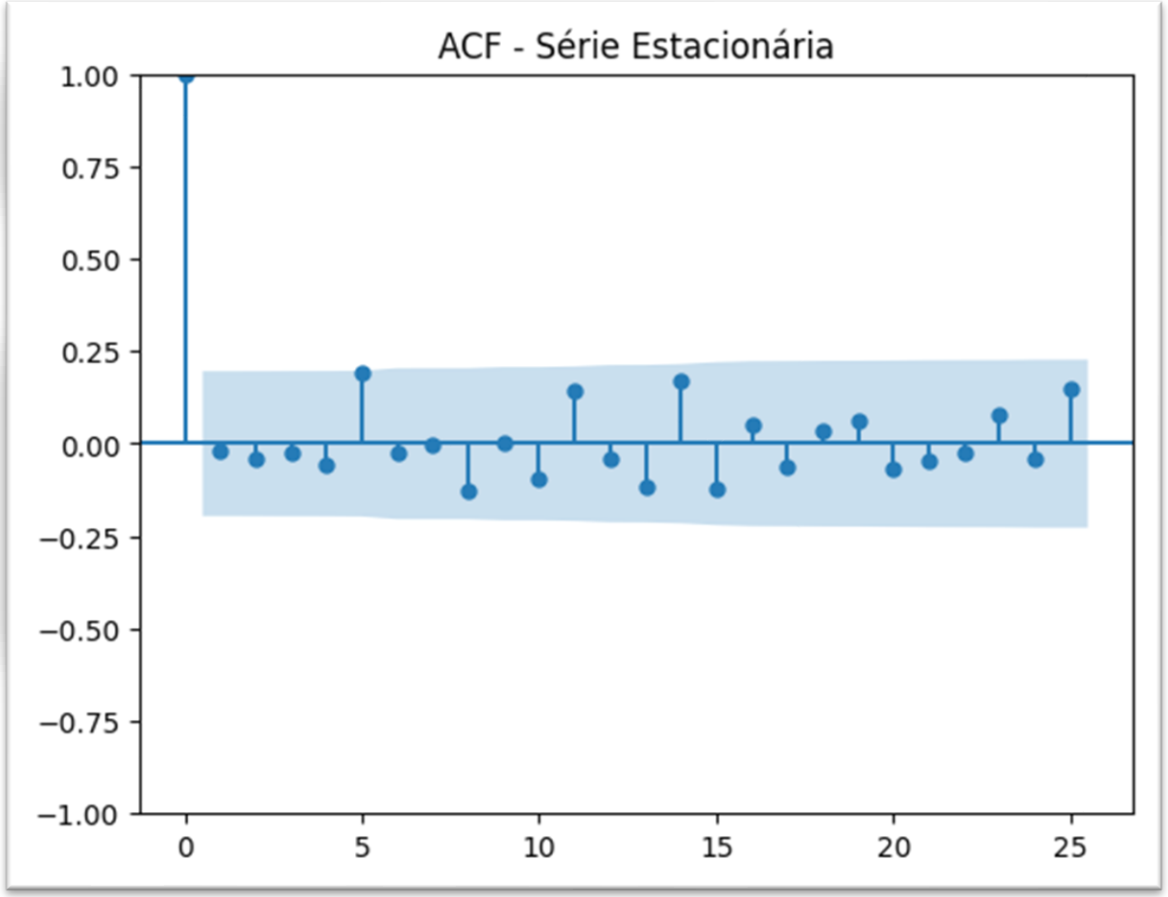

A região marcada no gráfico do plot_acf indica a faixa de confiança, normalmente de 95%.

Plot: com biblioteca – mais simples

Um jeito muito mais simples de plotar esses gráficos é utilizar a função **plot_acf**:

```
from statsmodels.graphics.tsaplots import plot_acf
```

```
# plot das autocorrelações com statsmodels (ACF)
plt.figure(figsize=(10, 4))
plot_acf(serie_estacionaria, lags=max_lag, title='ACF - Série Estacionária')
plt.show()

plt.figure(figsize=(10, 4))
plot_acf(serie_nao_estacionaria, lags=max_lag, title='ACF - Série Não Estacionária')
plt.show()
```

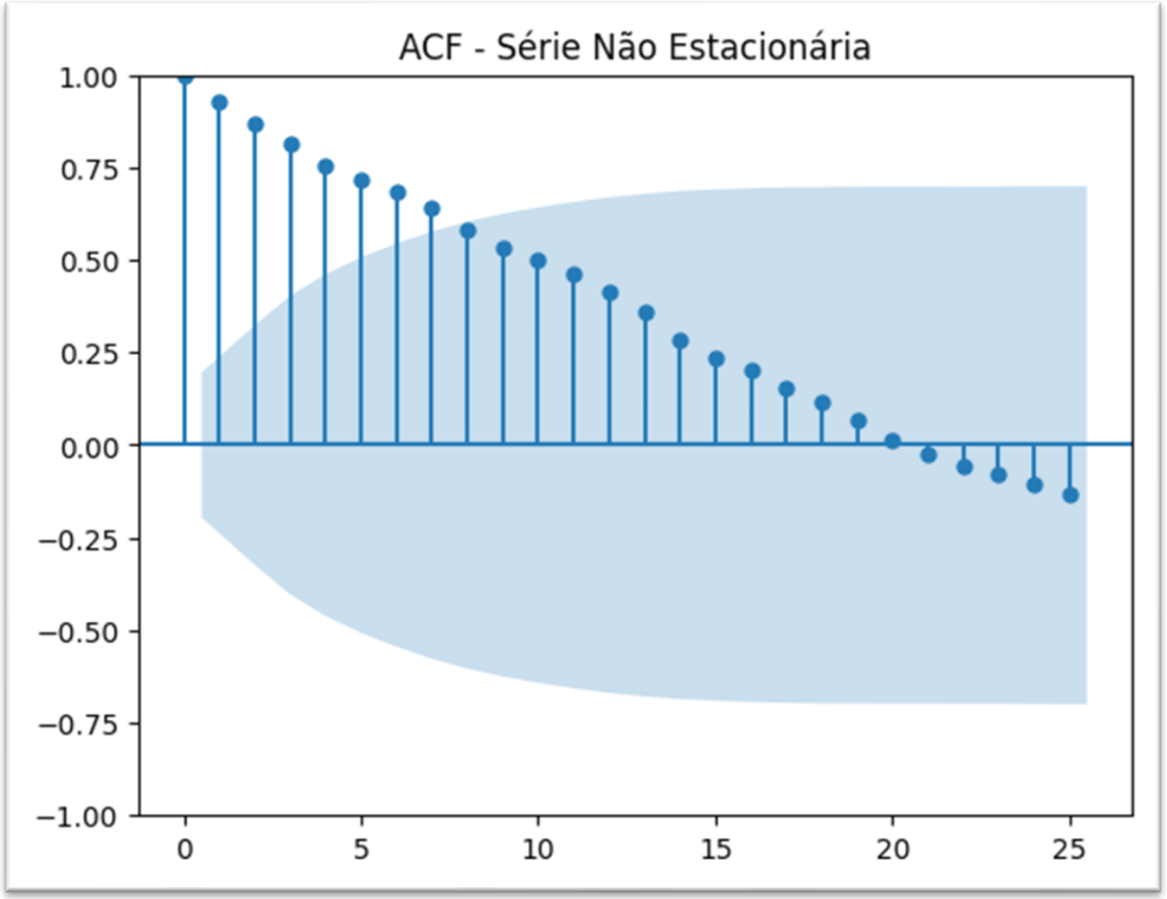

O que analisar?

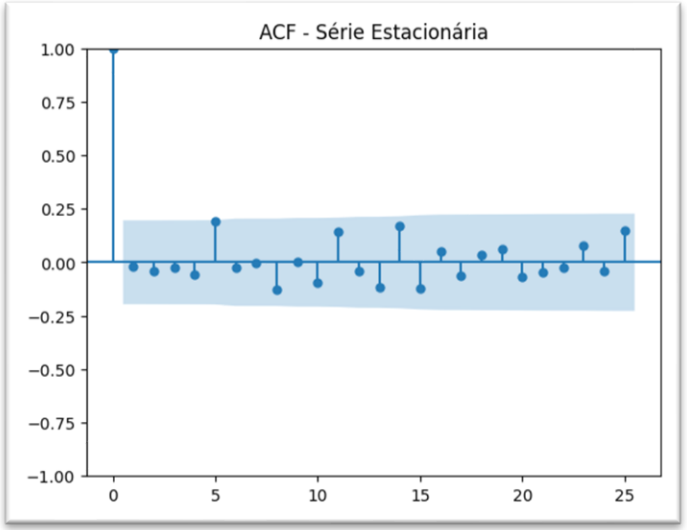

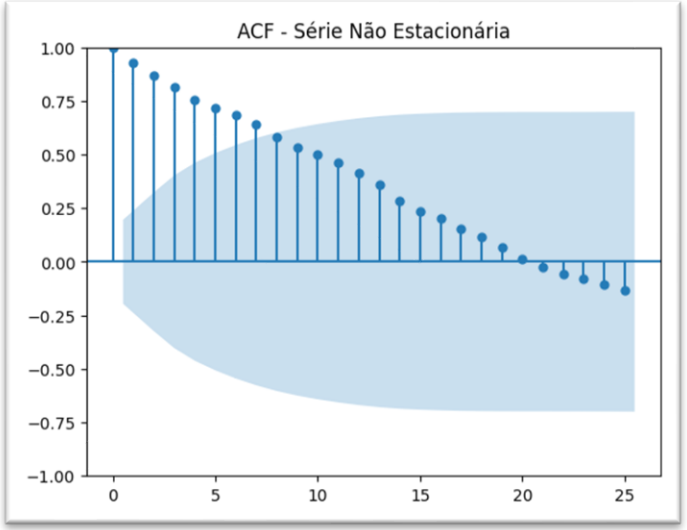

O gráfico da ACF mostra o quanto o valor atual está ligado aos valores anteriores. Se a autocorrelação desaparece rapidamente, a série esquece o passado então é estacionária. Se ela continua alta por muito tempo, os choques persistem então não é estacionária.

Se as barras caem rápido, parece estacionária

Se as barras ficam altas por muito tempo, parece não estacionária

Posso considerar mais lags ?

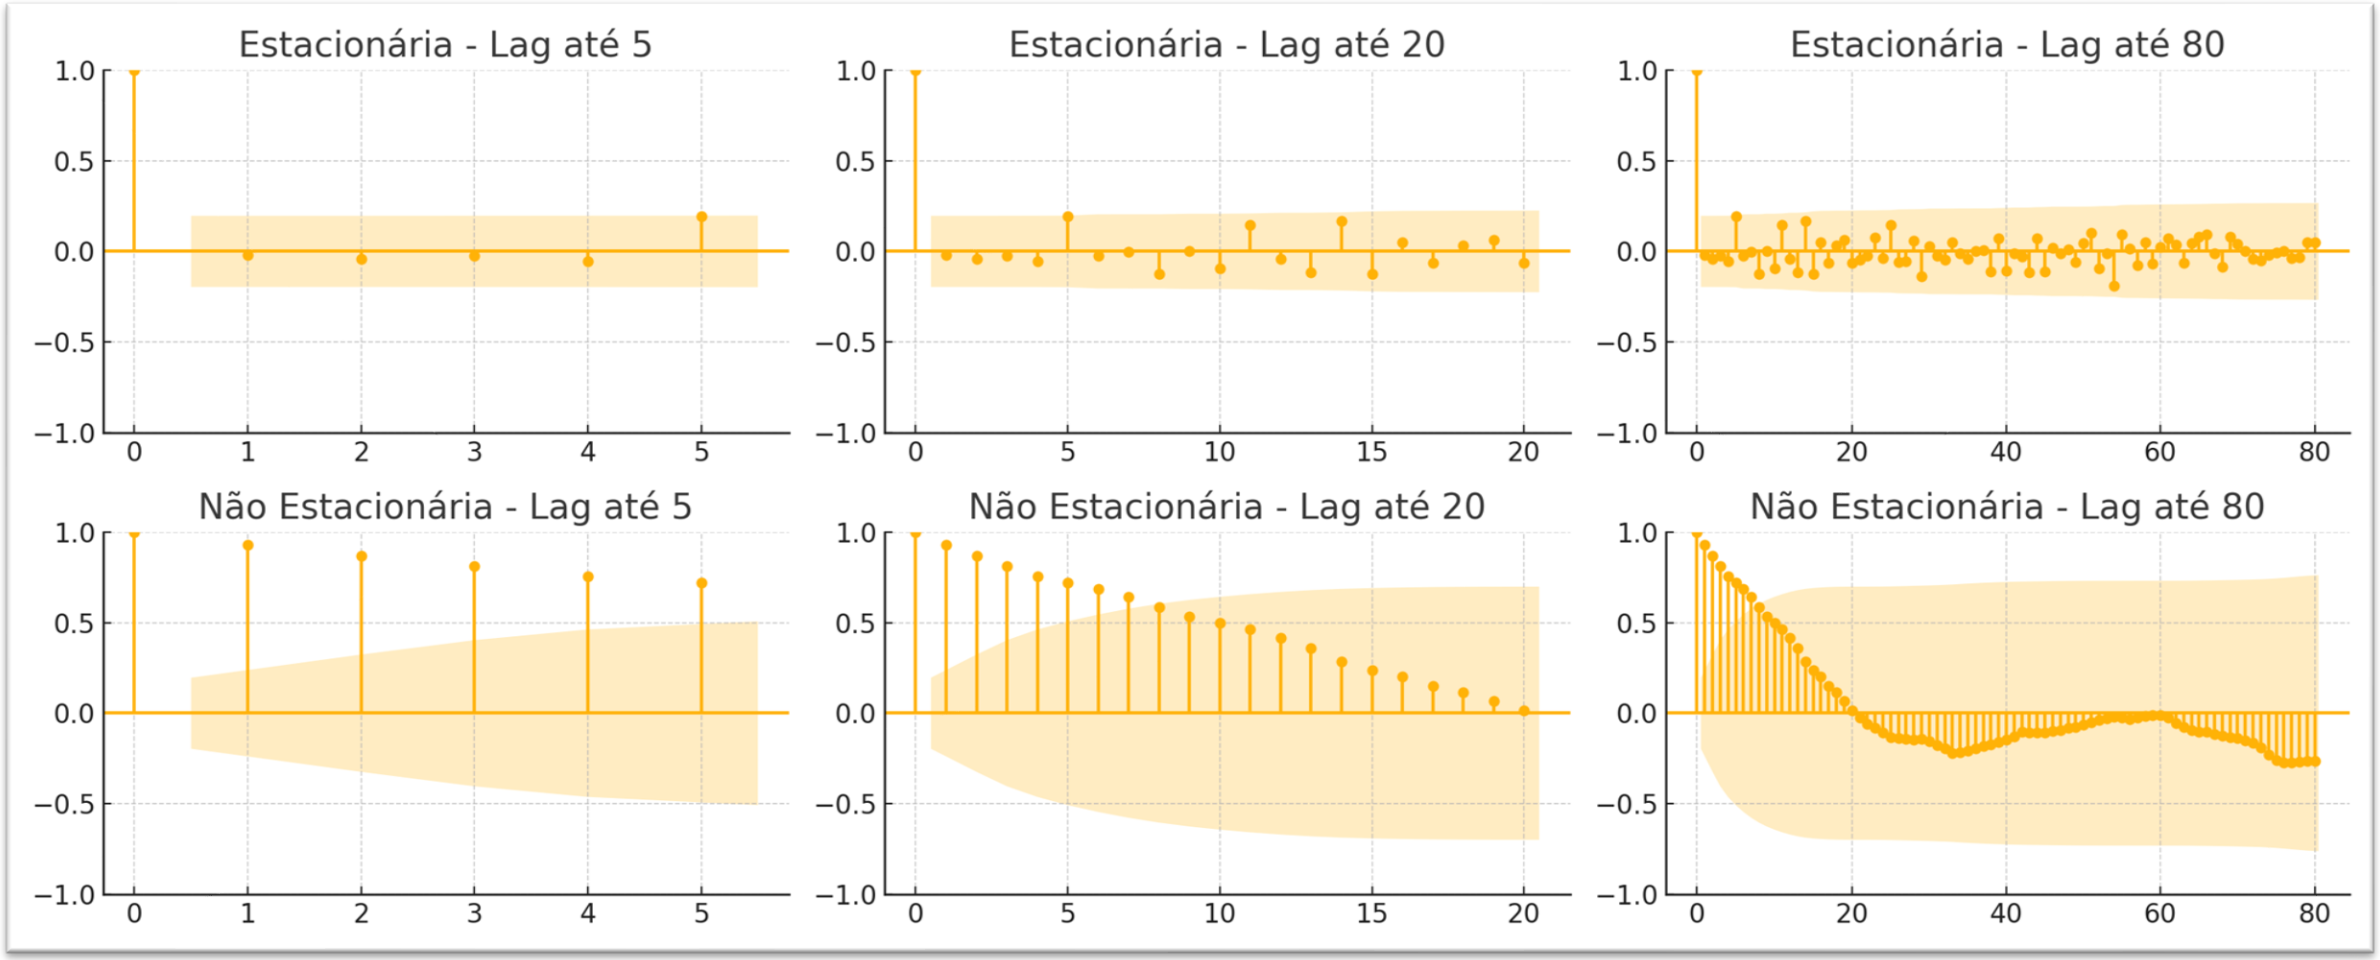

Devo analisar somente os gráficos?

Quando plotamos o ACF, estamos observando na prática se a série tem memória longa — isto é, se os valores passados continuam influenciando os atuais por muitos períodos.Isso é o que chamamos de não estacionariedade, e a persistência da autocorrelação alta por muitos lags é um sinal disso.

Mas como o ACF pode ser enganado por ruído ou por séries pequenas, usamos os **testes formais de estacionariedade para confirmar com rigor estatístico o que suspeitamos.**

Testes de Estacionariedade

Os testes:

Ferramenta	O que faz	É necessário?	Para que serve?
ACF	Mostra visualmente a memória da série	Recomendado (visual)	Exploração inicial, sinal de estacionariedade
ADF	Testa se a série **não é estacionária**	Sim	Diagnóstico estatístico
KPSS	Testa se a série **é estacionária**	Sim	Diagnóstico estatístico complementar

Testes: ADF

Teste de Dickey-Fuller (ADF):

- H_0: não estacionária
- H_1: estacionária

Se:

- $p \leq 0.05 \rightarrow$ rejeita H_0
- $p > 0.05 \rightarrow$ não rejeita H_0

Queremos rejeitar H_0

```python
from statsmodels.tsa.stattools import adfuller
```

```python
# realizando o teste ADF e coletando resultados
resultado = adfuller(df['Valor'])

# apresentando resultados
print("Estatística ADF:", resultado[0])
print("p-valor:", resultado[1])
print("Valores críticos:")
for chave, valor in resultado[4].items():
    print(f"  {chave}: {valor}")
```

Testes: ADF

Para o arquivo serie1.xls, temos o seguinte resultado:

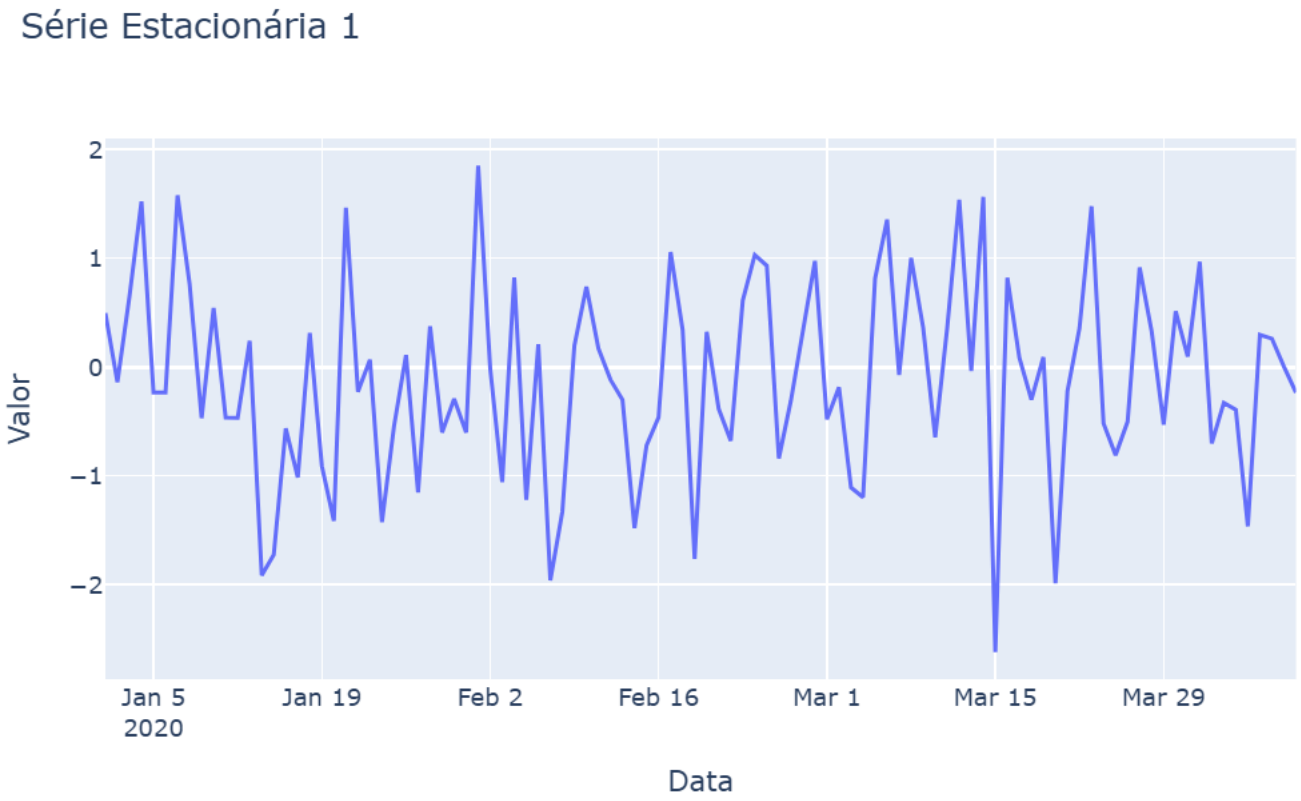


```
Estatística ADF: -10.08442591366971
p-valor: 1.1655044784188918e-17
Valores críticos:
  1%: -3.498198082189098
  5%: -2.891208211860468
  10%: -2.5825959973472097
Série Estacionária
```

Testes: KPSS

Teste de KPSS:

- H_0: estacionária
- H_1: não estacionária

Se:

- $p \leq 0.05 \rightarrow$ rejeita H_0
- $p > 0.05 \rightarrow$ não rejeita H_0

Queremos NÃO rejeitar H_0

```python
from statsmodels.tsa.stattools import kpss
```

```python
# KPSS
resultado = kpss(df['Valor'], regression='c')
print(resultado)

# resultados
print(f"Estatística KPSS: {resultado[0]}")
print(f"Valor-p: {resultado[1]}")
print("Valores críticos:")
for chave, valor in resultado[3].items():
    print(f"  {chave}: {valor}")
```

Estatísticas Dinâmicas: média móvel

Resultado ADF	Resultado KPSS	Conclusão segura?	Interpretação prática
Rejeita H_0	Não rejeita H_0	Sim	Série é **estacionária** (os dois concordam)
Não rejeita H_0	Rejeita H_0	Sim	Série é **não estacionária** (os dois concordam)
Rejeita H_0	Rejeita H_0	Não	Inconclusivo — os dois discordam
Não rejeita H_0	Não rejeita H_0	Não	Inconclusivo — os dois são conservadores

Desafio

Realize os testes de estacionariedade para as séries anteriores

Instituto J&F

Centro de Educação para os Negócios